

Otimização da Mesclagem de Interrupções em Infraestruturas em Nuvem

Eduardo Hideo Kuroda

QUALIFICAÇÃO DE MESTRADO APRESENTADA
AO
INSTITUTO DE MATEMÁTICA E ESTATÍSTICA
DA
UNIVERSIDADE DE SÃO PAULO
PARA
OBTENÇÃO DO TÍTULO
DE
MESTRE EM CIÊNCIA DA COMPUTAÇÃO

Programa: Mestrado em Ciências da Computação

Orientador: Prof. Dr. Daniel Macêdo Batista

Durante o desenvolvimento deste trabalho o autor recebeu auxílio financeiro da Comissão Europeia e da Coordenação de Aperfeiçoamento de Pessoal de Nível Superior

São Paulo, julho de 2012

Otimização da Mesclagem de Interrupções em Infraestruturas em Nuvem

Proposta de dissertação apresentada ao
Instituto de Matemática e Estatística da Universidade de São Paulo
como requisito parcial para qualificação de
Mestre em Ciência da Computação.

Resumo

Uma infraestrutura em nuvem é formada por máquinas virtuais. Estas possuem funcionalidades que as tornam atrativas para o mercado como a migração e a escalabilidade de recursos. Porém, as mesmas se comportam com um desempenho baixo se comparado com infraestruturas sem virtualização, principalmente quando pensamos em implantar aplicações intensivas de rede.

Uma das principais causas é a arquitetura da virtualização de rede. Diferente da arquitetura de rede padrão, há alguns passos adicionais para transmitir e receber um pacote de informação dentro de uma máquina virtual o que implicam em um custo adicional tanto na memória como no processamento.

Para reduzir o custo do processamento, uma ideia é agrupar uma quantidade grande de pacotes para recebê-las em rajadas, isso faria interromper menos o processador e reduzir a quantidade de processamento por pacotes, mas em troca aumentaria a latência da rede. Essa estratégia é chamada de mesclagem de interrupções.

Assim, essa pesquisa tem como objetivo criar um algoritmo para otimizar a mesclagem de interrupções tentando garantir uma melhor qualidade dos serviços dentro da infraestrutura.

Palavras-chave: computação em nuvem, virtualização de rede, mesclagem de interrupções

Abstract

Abstract ...

Keywords: cloud computing, network virtualization, interrupt coalescing

Sumário

Lista de Abreviaturas	vii
Lista de Figuras	ix
Lista de Tabelas	xi
1 Introdução	1
1.1 Considerações Preliminares	1
1.2 Objetivos	1
1.3 Contribuições	1
1.4 Organização do Trabalho	2
2 Conceitos	3
2.1 Computação em Nuvem	3
2.1.1 Uso da virtualização	3
2.2 Virtualização	3
2.2.1 Virtualização de servidores	3
2.2.2 Virtualização de dispositivos de E/S	4
2.2.3 Virtualização da Rede	5
2.2.4 Virtualização da Rede no XEN	5
2.3 Mesclagem de Interrupções	7
2.3.1 Transmissão x Recepção	7
2.3.2 virtualização de rede	7
3 Revisão Bibliográfica	9
3.1 Objetivo	9
3.2 Critérios de Seleção	9
3.3 Execução	9
3.3.1 Resumo Sintetizado	9
3.3.2 Análise das Informações	12
3.3.3 Conclusão	13
4 Proposta	15
4.1 Tema de Pesquisa	15
4.2 Problema de Pesquisa	15
4.3 Evidências do problema	15

4.4	Relevância do problema	15
4.5	Propostas da Literatura	15
4.6	Proposta de pesquisa	15
4.7	Questão de pesquisa	16
4.8	Método de pesquisa	16
4.9	Cronograma	16
Referências Bibliográficas		17
Índice Remissivo		19

Lista de Abreviaturas

MV	máquina virtual (<i>virtual machine</i>)
CPD	centro de processamento de dados (<i>datacenter</i>)
CPU	unidade central de processamento (<i>central processing unit</i>)
E/S	entrada/saída (<i>In/Out</i>)
DMA	acesso direto a memória (<i>direct memory access</i>)
IOMMU	unidade de gerenciamento de E/S da memória (<i>input/output memory management unit</i>)
dom0	domínio 0 (<i>domain zero</i>)
domU	domínio do usuário (<i>user domain</i>)
CDNA	acesso direto a memória concorrente (<i>concurrent direct network access</i>)
IRQ	pedido de interrupção (<i>interrupt request line</i>)
MTU	unidade máxima de transmissão (<i>maximum transmission unit</i>)
SR-IOV	virtualização de E/S de raiz única (<i>single root I/O virtualization</i>)
IaaS	infraestrutura como um serviço (<i>Infrastructure as a service</i>)
IP	protocolo de Internet (<i>Internet Protocol</i>)

Lista de Figuras

2.1	ponte virtual criada no XEN [Eas07]	6
2.2	arquitetura da rede virtual no XEN [STJP08]	6

Lista de Tabelas

2.1	parâmetros para mesclagem de interrupções	7
3.1	Artigos selecionados e suas relevâncias	10

Capítulo 1

Introdução

Numa infraestrutura de nuvem, os recursos são controlados pelo fornecedor e alocados de maneira elástica de acordo com a necessidade do consumidor [GED⁺11]. Para obter essa ‘elasticidade’, normalmente, a nuvem adotada uma tecnologia chamada virtualização.

A virtualização divide um recurso poderoso em recursos menores chamados de máquinas virtuais [BDF⁺03]. Com recursos menores, é possível fornecer ao consumidor uma quantidade menor de recursos computacionais que ainda satisfaçam seus requisitos e também alocar mais sob demanda [AFG⁺09].

Apesar das máquinas virtuais ajudarem a aumentar a flexibilidade, elas ainda têm um desempenho abaixo da máquina pura quando executamos aplicações que usam muito a rede [CCW⁺08] [EF10] [Liu10] [WR12] [Rix08].

Uma das principais causas é a arquitetura da virtualização de rede. Diferente da arquitetura de rede padrão, há alguns passos adicionais para transmitir e receber um pacote de informação que implicam em um custo adicional tanto na memória como no processamento [CCW⁺08] [EF10] [Liu10] [WR12] [Rix08].

Para reduzir o custo do processamento, uma ideia é agrupar uma quantidade grande de pacotes para enviá-las ou recebê-las em rajadas, isso faria interromper menos o processador e reduzir a quantidade de processamento por pacotes [AMN06] [CCW⁺08].

Assim, essa pesquisa foca em automatizar a configuração de mesclagem de interrupções do *driver* da placa de rede virtual e física, tentando ajustar esse parâmetro dinamicamente de forma a garantir uma melhor qualidade do serviço da infraestrutura.

1.1 Considerações Preliminares

Esse trabalho está direcionado para contribuições em específico na área de computação em nuvem e redes pelo interesse do autor.

1.2 Objetivos

O objetivo dessa pesquisa é fornecer um algoritmo de mesclagem de interrupções a fim de garantir a qualidade do serviço prestado pelas máquinas virtuais dentro da nuvem para diferentes tipos de aplicações.

1.3 Contribuições

As principais contribuições desse trabalho são:

- Fornecer um algoritmo capaz de garantir uma melhor qualidade na infraestrutura de nuvem para diferentes tipos de aplicações.

- Automatizar as configurações de mesclagem de interrupção do *driver* da placa de rede física e virtual de forma que eles se adaptem a diferentes infraestruturas e aplicações.

1.4 Organização do Trabalho

No Capítulo 2, apresentamos os conceitos de virtualização de servidores, virtualização de E/S, virtualização de rede, mesclagem de interrupções e Computação em nuvem. No Capítulo 3, apresentamos uma revisão bibliográfica na área de virtualização de rede. Finalmente, no Capítulo 4, apresentamos uma proposta na área de virtualização de rede.

Capítulo 2

Conceitos

2.1 Computação em Nuvem

A computação em nuvem refere-se tanto a aplicações fornecidas como serviços por meio da Internet como também a sistemas de hardware e software das CPDs (Centro de Processamento de Dados) que fornecem os serviços [AFG⁺09].

Como o termo nuvem é muito abrangente, ele foi dividido em várias classificações [AFG⁺09], entre elas, o tipo de serviço o qual fornecem. Nesse texto, quando falamos de nuvem, estaremos nos referindo a serviços que fornecem uma infraestrutura (IaaS). Cada infraestrutura pode receber várias requisições de hospedar programas de desenvolvedores e, nesse caso, terá que implantá-los em algum local no interior dela. Quando um cliente, em algum momento, faz uma requisição para executar esse programa, a nuvem executa o programa internamente e repassa o resultado ao cliente.

Para que isso seja possível, a infraestrutura de nuvem contém vários nós, os quais são recursos físicos como computadores e CPDs, que contém e controlam várias máquinas virtuais (MV) usando alguma técnica de virtualização. Cada requisição para implantar ou executar um programa é feita oferecendo as máquinas virtuais as quais estão dentro de um nó da infraestrutura.

2.1.1 Uso da virtualização

Na computação em nuvem, em particular quando se é fornecido uma infraestrutura para implantar aplicações (IaaS), a adoção da virtualização melhora a utilização dos recursos e protege o servidor de problemas que os softwares dos clientes possam causar em relação a servidores com máquinas puras [CCW⁺08].

Como consequência, também permite um novo modelo de negócio chamado “pague somente quando usa”, onde o cliente paga somente pelo tempo que o recurso é usado. Além disso, o cliente tem a impressão de estar utilizando um ambiente com recursos infinitos, já que a configuração de uma máquina virtual pode ser ampliada sem interrupção do serviço e, mais máquinas podem ser agregadas para prover o serviço [AFG⁺09].

Essas características beneficiam o lado do servidor, que não precisará fornecer um recurso físico inteiro para cada cliente e terá maior segurança e tolerância a falhas, já que cada sistema é independente. Do lado do cliente, ele irá economizar dinheiro pelo novo modelo de negócio e terá recursos sob demanda.

2.2 Virtualização

2.2.1 Virtualização de servidores

Os servidores normalmente são constituídos de CPDs que estão ligados de alguma forma por uma rede. Quando queremos fornecer recursos de maneira eficiente, uma tecnologia popularmente utilizada é a virtualização [GED⁺11]. A virtualização divide um computador, geralmente com grande capacidade de processamento, em recursos menores chamados de máquinas virtuais de

modo que cada uma age como se fosse um computador separado podendo ter inclusive diferentes sistemas operacionais [BDF⁺03].

Com recursos menores, é possível fornecer ao consumidor uma quantidade menor de recursos computacionais que ainda satisfaçam seus requisitos e também alocar mais sob demanda [AFG⁺09]. Segundo [CCW⁺08], as estratégias de virtualização podem ser divididas em 4 grandes categorias: virtualização completa, para-virtualização, virtualização em nível de sistema operacional e virtualização nativa.

Na virtualização completa também conhecida como emulação de hardware, um ou vários sistemas operacionais são executados dentro de um *hypervisor*. O *hypervisor*, chamado também de gerenciador de máquinas virtuais, fornece uma plataforma para os sistemas operacionais das máquinas virtuais e gerencia a execução delas.

No *hypervisor* da virtualização completa, é feita a interceptação, tradução e execução das instruções sob demanda dos sistemas operacionais das máquinas virtuais. Nessa estratégia, o núcleo do sistema operacional que roda o *hypervisor* não necessita de modificações. Dentro dessa categoria estão o *KVM*, o *XEN*, o *VMWare* e o *VirtualBox*.

Diferente da virtualização completa, a para-virtualização exige uma modificação do núcleo para poder executar o *hypervisor*. Assim, caso não exista o código-fonte do sistema, não é possível usar essa estratégia. Nele, o hardware virtual consegue conversar diretamente com o dispositivo emulado. Isso garante uma carga extra mínima em relação a tentar emular o dispositivo real. Nessa categoria estão incluídos o *XEN*, o *VMWare*.

A virtualização em nível de sistema operacional não tem um *hypervisor*. Ela modifica o núcleo do sistema operacional isolando múltiplas instancias do sistema dentro de uma máquina física. Nesse caso, como é feito apenas um isolamento entre os sistemas, estas ficam limitadas a terem o mesmo sistema operacional. Está incluído nessa categoria o *OpenVZ*.

Por fim, a virtualização nativa aproveita o suporte de *hardware* para virtualização dentro do próprio processador. Isto permite que múltiplos sistemas operacionais rodem sobre outros, sendo capazes de cada um acessar diretamente o processador do hospedeiro. Como exemplos temos o *XEN*, o *VMWare* e o *VirtualBox*.

A virtualização completa e nativa tem uma grande vantagem em relação as outras: não é necessário mexer no núcleo do sistema o que as tornam mais simples e mais portátil já que sistemas operacionais com código fechados o podem usar. A para-virtualização e virtualização em nível de sistema operacional exige uma modificação no núcleo, porém, são os que tem um melhor desempenho pois tem acesso ao hardware diretamente. Comparando as duas, a virtualização em nível de sistema operacional é bem mais intrusivo e limita o sistema operacional das instancias, mas também tem um desempenho melhor que a para-virtualização [CCW⁺08].

2.2.2 Virtualização de dispositivos de E/S

Com a virtualização de servidores, os dispositivos de E/S físicos passam a ter que sofrer modificações já que em um servidor não tem apenas um único sistema operacional, mas sim, várias máquinas virtuais com um sistema dentro de cada uma.

[Rix08] separou a virtualização de E/S em duas categorias: privada ou compartilhada.

Na virtualização de E/S privada, cada dispositivo físico é associado a apenas uma única MV enquanto que na virtualização de E/S compartilhada, o dispositivo é compartilhado para várias MV.

Comparando a virtualização de E/S privada com a compartilhada há uma subutilização na virtualização privada, pois parte do tempo em que a MV não usa o dispositivo é desperdiçada. Por outro lado, o desempenho da virtualização compartilhada é pior já que divide o recurso com outras máquinas.

Quando pensamos em escalar o número de MVs, o custo da virtualização privada se cresce absurdamente (com 10 MVs teríamos que ter 10 dispositivos físicos enquanto que na virtualização compartilhada, talvez até um dispositivo poderia ser o suficiente para resolver o problema).

Normalmente, queremos que o dispositivo físico seja compartilhado entre as máquinas, tanto pela possibilidade de escalar como pelo custo. Porém, disponibilizar de maneira compartilhada o acesso a dispositivos físicos pode trazer muitos problemas de segurança, dificultar o monitoramento das informações e a migração de máquinas virtuais [STJP08].

Para contornar esse problema, normalmente, *hypervisores* como *XEN*, *KVM* e *VMWare* restringem o acesso a um dispositivo físico para apenas uma máquina virtual e o acesso a esse dispositivo pelas outras máquinas virtuais é feito através dessa máquina. Essa restrição traz uma perda de desempenho em relação a ambientes que não usam virtualização quando o uso da rede é intensa, por exemplo [CCW⁺08] [EF10] [Liu10].

[WR12] fez algumas menções sobre o uso de técnicas de virtualização de E/S. Dentre as vantagens, ele cita a melhor utilização dos recursos e a economia de custos em relação a sistemas que estão com a implementação física acoplada com o dispositivo lógico, pois vários sistemas podem aproveitar o mesmo recurso. Em relação a flexibilidade, é possível mapear os dispositivos lógicos com as implementações físicas, garantindo uma maior portabilidade. Esse mapeamento pode também trazer novas funcionalidades ao recurso como: balanceamento da carga de trabalho e mascaramento das falhas.

A funcionalidade de suspender, migrar e resumir uma máquina virtual também é possível, pois com o dispositivo lógico desacoplado da implementação física, é possível reconectar a máquina virtual em outra máquina física com uma configuração diferente.

Outra funcionalidade trazida com a virtualização é a interposição e transformação das requisições virtuais de E/S. Isso permite que as requisições que passam pelo dispositivo lógico sejam transformadas. Em um exemplo de leitura e escrita no disco, além de simplesmente ler/escrever no disco, é possível guardar uma cópia da informação antiga como cópia de segurança para conseguir num momento futuro, "viajar no tempo" e desfazer algo que foi feito. Outra ideia é criptografar a informação quando alguém escrever no disco, dificultando outras pessoas de acessarem o seu conteúdo escrito.

2.2.3 Virtualização da Rede

A virtualização de rede que também é um dispositivo de E/S tem algumas particularidades em relação a outros dispositivos. Segundo [Rix08], Comparando a virtualização de E/S com a virtualização de rede, a complexidade de virtualizar a rede é muito maior pelo fato de não se conhecer o destino de uma informação e a necessidade de estar preparado a qualquer momento para receber e responder ao tráfego da rede, diferentemente da virtualização de disco em que a leitura e escrita só ocorre quando requisitado pela máquina virtual.

2.2.4 Virtualização da Rede no XEN

Apesar da implementação dada ser específica para o *XEN*, outros *hypervisores* como *WMware* e *KVM* adotam uma arquitetura semelhante [STJP08].

No *XEN*, para todas as máquinas conseguirem acessar o dispositivo de rede ao mesmo tempo, temos dois tipos de configuração: ponte e roteamento.

Na configuração de ponte, uma ponte virtual(`xenbr0`) é criada dentro do `dom0` como é possível ver na Figura 2.1. Essa ponte está ligada na interface de rede física pela porta `peth0`. A porta `vif0.0` está sendo usada para tráfegos de/para `dom0` e as portas `vifX.0`, onde *X* é um valor maior que 0, estão sendo usadas para tráfegos de/para algum `domU`.

Como é possível observar, todo pacote que é recebido ou transmitido para alguma máquina virtual tem que passa pela ponte.

Na configuração de roteamento o `dom0` cria uma ligação entre ele e cada `domU`. Rotas de cada `domU` são adicionados na tabela de roteamento do `dom0`, nesse caso o *IP* de cada *domU* tem que ser estático.

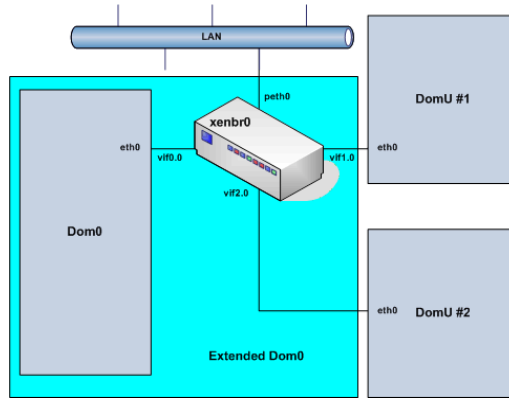


Figura 2.1: ponte virtual criada no XEN [Eas07]

Na Figura 2.2 vemos a arquitetura da rede virtual no XEN. Para transmitir/receber um pacote no domínio hospedeiro (domU) é necessário usar o canal de E/S. Esse canal consiste de um mecanismo de notificação de evento e um *buffer* de descrição em anel onde guarda os detalhes de requisições entre o *driver* de *frontend* (*netfront*) e o *driver* de *backend* (*netback*).

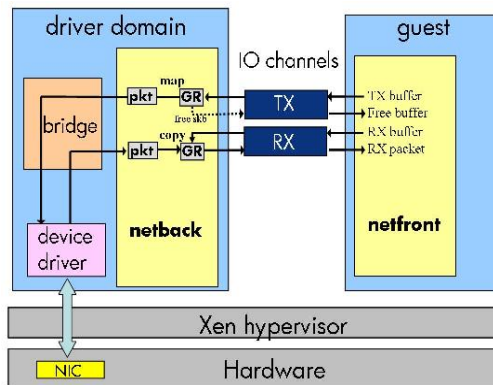


Figura 2.2: arquitetura da rede virtual no XEN [STJP08]

O mecanismo de notificação de evento avisa que alguém de um domínio escreveu no *buffer* de E/S. Isso é feito através de uma interrupção virtual no outro domínio.

Para o domínio do controlador dos *drivers* físicos (domínio do *driver*) ter acesso ao *buffer* de E/S dentro da memória do hospedeiro, é necessário um mecanismo de permissão. Neste, o domínio do hospedeiro fornece páginas da sua memória para serem usadas como *buffer* de E/S. Essas páginas são passadas como referência na descrição da requisição.

Na transmissão, o domU coloca um pacote no *buffer* de E/S e a sua página de referência no *buffer* de descrição e notifica o domínio do *driver*. Este então mapeia as páginas recebidas no seu espaço de endereços e pede para o dispositivo de E/S físico transmiti-la, quando o dispositivo o dispositivo termina a transmissão, o domU libera a página.

Na recepção, o domínio hospedeiro informa as possíveis páginas da memória que podem ser escritas e quando algum pacote chega pelo dispositivo físico, o dispositivo físico envia uma interrupção de chegada de pacote ao domínio do *driver*, o *netback* o copia para uma página da memória que foi fornecida e envia uma interrupção para o *netfront*. Quando o *netfront* recebe uma notificação, ele pega o que está no *buffer*, manda para o seu sistema e libera o *buffer*.

2.3 Mesclagem de Interrupções

Quando a recepção de pacotes é muito rápida no meio físico, a quantidade de interrupções devido a chegada de pacotes é muito grande podendo sobrecarregar o processamento.[DXZL11]. Isso ocorre porque as interrupções têm prioridade absoluta sobre todas as outras tarefas e se a taxa de interrupções é suficientemente elevada, o sistema gastará todo seu tempo para respondê-la e o rendimento do sistema cairá para zero. [Sal07].

Várias soluções são propostas na literatura para resolver esse problema: mesclagem de interrupções [Sal07], copia-zero [STJP08], *scatter/gather* [CRKH05], *TSO* [Cor09], *GRO* [Cor09].

O foco dessa pesquisa está na mesclagem de interrupções que pode ser feita através de um conjunto de parâmetros do *driver* de redes. O objetivo dele é reduzir a quantidade de interrupções na transmissão/recepção de pacotes dentro de um intervalo de tempo ou número de pacotes em troca de aumentar a latência da rede.

Para isso é possível manipular 4 parâmetros, `tx-frames`, `rx-frames`, `tx-usecs`, `rx-usecs`. A descrição de cada parâmetro está na tabela 2.1. Como pode-se notar a mesclagem de interrupções depende do tamanho do *buffer* de transmissão e recepção. O *buffer* pode ser tanto um espaço de memória da máquina(usando DMA) como uma memória interna da placa de rede. Caso este seja pequeno, vários pacotes serão descartados durante o tráfego de pacotes por falta de espaço, caso seja grande, pode aumentar a latência por ter muitos pacotes em espera dentro dele.

O NAPI [CRKH05] é uma interface para usar técnicas de mesclagem de interrupções para dispositivo de rede no núcleo do Linux. O objetivo dele é reduzir a carga extra do processamento na recepção de pacotes. Para isso, no momento em que há uma grande quantidade de tráfego, o núcleo desabilita as interrupções, passa a checar continuamente a chegada de pacotes na rede e caso o sistema não dê conta de manipular os pacotes, ele passa a jogá-los fora antes de levá-los ao núcleo. Esse processo é chamado de *polling*. Quando o tráfego é reduzido o núcleo volta a forma padrão de recepção.

Tabela 2.1: *parâmetros para mesclagem de interrupções*

nome	descrição
<code>tx-frame N</code>	gera uma interrupção quando a quantidade de pacotes dentro do buffer de transmissão chegar a N
<code>rx-frame N</code>	gera uma interrupção quando a quantidade de pacotes dentro do buffer de recepção chegar a N
<code>tx-usecs N</code>	gera uma interrupção N microssegundos depois que um pacote for transmitido
<code>rx-usecs N</code>	gera uma interrupção N microssegundos depois que um pacote for recebido

2.3.1 Transmissão x Recepção

Ambas a transmissão e a recepção de pacotes podem gerar interrupções com uma frequência grande. Porém, a transmissão

2.3.2 virtualização de rede

No contexto da virtualização de rede, como foi possível ver na arquitetura da virtualização da rede no *XEN*, muitos passos extras são feitos durante recepção e transmissão de pacotes, incluindo o aumento no número de interrupções.

Como foi possível observar, na virtualização de rede do *XEN*, dois *drivers* virtuais(*frontend*,*backend*) são criados pelo próprio *XEN* para ligar o *dom0* com um *domU*.

A estratégia de mesclagem então pode ser feita tanto no *driver* físico como no *driver* virtual de *frontend* e *backend*.

Capítulo 3

Revisão Bibliográfica

3.1 Objetivo

O objetivo dessa revisão foi analisar e estudar as maneiras já existentes de otimizar o desempenho da rede em infraestruturas de máquinas virtuais utilizados para a criação de nuvens e os problemas em aberto. Cada estratégia sugerida pode atender bem a um cenário, porém, em outros casos, essa mesma estratégia pode ser pouco eficiente devido a dinamicidade da rede e os diferentes requerimentos de um usuário.

3.2 Critérios de Seleção

Para seleção das referências, em cada artigo encontrado pela estratégia de busca será lido o seu resumo e classificado manualmente em três categorias de acordo com sua relevância: alta, média, baixa.

Os artigos de relevância alta serão lidos por completo e resumidos. Os artigos médios terão a leitura de sua introdução e a mudança da sua relevância para baixa ou alta. Por fim os artigos baixos não serão lidos.

3.3 Execução

A tabela 3.1 mostra os artigos coletados e sua relevância.

3.3.1 Resumo Sintetizado

Em [CCW⁺08] o autor fez uma comparação entre diferentes tecnologias de virtualização. Nos experimentos foi concluído que o *hypervisor* XEN tem um desempenho baixo em termos de atraso na rede, porém alto em termos de largura de banda em relação a um ambiente com OpenVZ e um ambiente sem virtualização, enquanto que o OpenVZ tem uma perda considerável em largura de banda, mas um atraso pequeno. Os autores de [CCW⁺08] não entram em detalhes sobre os motivos dos resultados terem sido esses.

[EF10] estudou a relação entre o número de núcleos e o número de MVs usando XEN e Eucalyptus como infraestrutura de nuvem. Foi concluído que a virtualização funciona bem para aplicações que não se comunicam muito, enquanto que em aplicações que são sensíveis a latência, houve uma perda de desempenho em relação a um ambiente não virtualizado. Outra conclusão foi que quanto maior o número de máquinas virtuais, maior a sobrecarga na CPU. A explicação para isso, segundo o autor, está na forma como foi implementada a virtualização da rede. O hardware físico só pode ser controlado por um sistema (dom0), enquanto que os outros (domUs) para conseguir fazer alguma operação de E/S pela rede, tem que passar por esse sistema através de um canal. Isso forma um

Tabela 3.1: *Artigos selecionados e suas relevâncias*

artigo	relevância
[CCW ⁺ 08]	alta
[EF10]	alta
[WR12]	alta
[Liu10]	alta
[Rix08]	alta
[SBB ⁺ 07]	média-baixa
[STJP08]	alta
[ON09]	alta
[Cor09]	alta
[LGBK08]	média-baixa
[AMN06]	alta
[JSJK11]	alta
[FA12]	alta
[DXZL11]	alta

gargalo no dom0.

[Rix08] fez uma revisão sobre a virtualização de rede. No texto o autor cita que a virtualização de rede impacta diretamente no número de servidores que podem ser diretamente consolidados dentro de uma única máquina física. Porém, as técnicas modernas de virtualização têm gargalos significantes, o que limita o desempenho da rede. Ele sugere um ganho de desempenho fazendo o dispositivo ter a capacidade de ler e escrever diretamente na memória da MV ao invés do processador da máquina virtual gerar interrupções cada vez que alguma informação entra ou sai pelo dispositivo. Essa funcionalidade é chamada acesso direto a memória (*DMA*). Apesar disso, o dispositivo pode escrever em uma posição da memória que não pertence a MV e, podendo assim, causar problemas em outros processos da máquina física. Assim, foi criada a unidade de gerenciamento de E/S da memória (*IOMMU*). No *IOMMU* a memória é restrita para o dispositivo de acordo com a máquina virtual que controla esse dispositivo. Como atualmente um processador possui vários núcleos, pode-se aproveitar esses núcleos para criar multi-filas nas interfaces de rede. O autor cita que pesquisadores do laboratório da HP e Citrix eliminaram a ponte no domínio de E/S para associar as máquinas virtuais diretamente com o *driver* de *backend* através das multi-filas, evitando a necessidade de sincronização das mensagens e multiplexação/demultiplexação da rede. Como benefícios do uso da multi-fila se teve: a redução da carga extra na fila e a eliminação de cópias entre o domínio de E/S e a máquina virtual, pois, a multiplexação não é feita. Por outro lado, seria necessário que cada informação seja enviada para a fila correta e que a CPU consiga aguentar a carga extra gerada pelas múltiplas filas.

Ainda em [Rix08], na arquitetura de virtualização de rede CDNA (*acesso direto a memória concorrente*) foi usada a ideia de multi-filas e em adição removeram o domínio de E/S. Sem o responsável por controlar as filas, o *hypervisor* passa a considerar cada conjunto de fila como um interface de rede física e a associa o controlador a uma MV. Assim, cada MV consegue enviar ou receber informações diretamente da rede sem nenhuma intervenção do domínio de E/S. Como consequência, a carga extra é reduzida pelo número reduzido de interrupções (antes era necessário interromper tanto o domínio de E/S como as MVs em cada transmissão/recepção). Pela MV poder acessar diretamente a interface de rede, ela também pode acessar algum local indevido da memória por *DMA*. Para contornar esse problema o autor sugeriu o uso de *IOMMU*.

[WR12] cita diversos desafios e problemas na área de virtualização de E/S: a carga extra no

hypervisor, a complexidade em gerenciar recursos (escalonamento e prioridades) e a dificuldade de dar uma semântica ao hardware virtual.

[Liu10] fez diversos experimentos com virtualização de E/S baseada em *software* (*virtio*) e em hardware (*SR-IOV*) usando o *hypervisor* KVM. O *virtio* é um padrão do linux para drivers de rede e disco que estão rodando em um ambiente virtual cooperado com um *hypervisor*, apesar de diferentes, ele tem o mesmo padrão arquitetural que a virtualização de rede do XEN. Já o *SR-IOV* é uma especificação que permite dispositivos pci-Express fornecerem interfaces extras com funcionalidades reduzidas para serem usadas pelas máquinas virtuais diretamente.

Foram analisadas diversas métricas: a largura de banda, a latência, chamadas para memória e comunicação entre máquinas.

Na latência, o *virtio* teve um desempenho muito baixo. A explicação, provada desabilitando a função de mitigação de transmissão, é que o hospedeiro atrasa o envio do pacotes para ser enviado em rajadas, mas mesmo assim, seu desempenho sem mitigação ainda perdeu próximo de 20 microsegundo em relação a máquina pura. Quando a opção de mitigação é desabilitada, isso provoca uma perda de desempenho pois cada pacote que é transmitido gera uma carga de trabalho no CPU, com a mitigação a carga por pacote é reduzida. Já o *SR-IOV* (single root I/O virtualization) teve um desempenho próximo da máquina pura perdendo apenas alguns microssegundos devido a virtualização da interrupção.

Na largura de banda, a transmissão em todos pareceu ter o mesmo desempenho. Já na recepção o *SR-IOV* se aproximou da máquina pura, mas o uso da sua CPU foi muito maior que as demais. No *virtio*, ele não conseguiu um bom desempenho, mas o uso de sua CPU foi baixa. No experimento de uso da memória na recepção, o *SR-IOV* teve um uso muito menor que o *virtio*, assim, o autor concluiu que o mal uso da largura de banda na recepção do *virtio* foi pelo uso excessivo da memória, o que explica também o baixo uso da CPU.

Nas transmissões de dados de MV, o *SR-IOV* teve um ganho muito maior que o *virtio*. A explicação do autor está na forma com que o *virtio* age quando tem uma alta carga na recepção, durante esse momento, ele troca a interrupção para um modo de pesquisa que reduz o número de interrupções e melhora o desempenho da rede. Na separação de custos, foi feita a separação do quanto foi utilizado de CPU para determinada tarefa. O resultado foi que o *virtio* gasta uma quantidade maior na virtualização e cópia, enquanto que o *SR-IOV* gasta uma quantidade maior em interrupções e nas máquinas virtuais.

[STJP08] propôs modificar a arquitetura do *driver* de E/S do XEN para conseguir melhorar o uso da CPU. Dentro dos problemas que ele encontra está o excesso de cópias de dados, a fragmentação de pacotes no *socket*, a falta de alinhamento do cache e o filtro de rede da ponte. Com algumas modificações ele conseguiu uma economia de 56% no uso do processador.

[ON09] analisou o desempenho de um sistema virtualizado com XEN aplicando a estratégia *LRO* (*large receive offload*) onde ainda dentro do *driver* da placa de rede é recebido e reunido os pacotes de informações que tiveram que ser segmentados. Nesse experimento eles mediram a vazão da rede variando o tamanho da mensagem e o tamanho da *MTU* (unidade máxima de transmissão). Os resultados mostraram um ganho de 8% a 14% na vazão da rede.

[xen12] sugere algumas práticas para tentar evitar um baixo desempenho em aplicações intensivas de rede/disco no XEN como dedicar exclusivamente um núcleo de processador ou uma quantidade de memória para o dom0.

[LGBK08] propôs duas otimizações na virtualização de rede: o escalonamento ciente de cache e o roubo de créditos de escalonamento para a recepção de pacotes. A primeira ideia é fazer com que o domU e o dom0 passem a compartilhar o cache, assim, a comunicação entre domínios é reduzida. A segunda otimização foca priorizar a recepção de pacotes onde o uso do processador é alto. Nos experimentos comparando a estrutura padrão de virtualização e a estrutura modificada com as

otimizações, foi apresentado um ganho de 96% na largura de banda.

[AMN06] pesquisaram as principais causas de carga extra na virtualização de E/S. No experimento eles estudaram dois modos de virtualização de E/S: o domU e o dom0 na mesma *CPU* e em *CPUs* distintas. O resultado mostrou que nas duas, tanto a transmissão como a recepção de pacotes perderam mais de 50% no desempenho comparado com a máquina física. Também foi notado que o rodar o domU e o dom0 em *CPUs* distintas é mais custoso que rodar elas juntas na mesma *CPU*.

[JSJK11] estudaram sacrificar o isolamento que existe entre as máquinas virtuais para conseguir reduzir a carga extra do processo. Os resultados mostram uma redução de 29% no uso do processador e 8% de ganho de banda na transmissão de pacotes grandes.

[FA12] fizeram experimentos em torno do problema da carga extra na virtualização da rede. Para isso eles propuseram adequar o balanço de interrupções para demonstrar a possibilidade de reduzir o número de pacotes perdidos. O resultado foi que um balanço adequado pode melhorar muito o desempenho, porém, o comportamento é difícil de ser previsto, dificultando a elaboração de um algoritmo.

Uma proposta futura sugerida foi deixar o núcleo do sistema automatizar o processo de balanço e analisar os resultados, quando aparecerem bons resultados, congelar a configuração de interrupção.

Eles também, no final, discutiram a possibilidade de usar a função de mesclagem existentes nos *drivers* das placas de rede modernas.

[DXZL11] propuseram otimizações para reduzir a carga extra na virtualização da rede. Uma das otimizações foi mesclar eficientemente as interrupções virtuais e a outra escalar o lado da recepção. A mesclagem de interrupção normalmente é usada quando a transferência de pacotes do meio físico é muito alta. Com uma transferência grande a placa de rede passa a trabalhar intensamente sobrecarregando o processador com interrupções. Na virtualização da rede, a transferência de pacotes passa a gerar interrupções físicas e virtuais. Interrupções virtuais são mais custosas em termos de ciclos de CPU em relação a interrupções físicas.

A mesclagem de interrupções virtuais pode ser feita no *driver* virtual de *backend* (na porte dentro do dom0) ou no *driver* virtual de *frontend* (dentro de um domU).

A ideia de escalar o lado da recepção foi baseado na ideia de paralelizar o *driver* virtual de *backend* tentando aproveitar melhor as propriedades de um processador multi-núcleo. Assim, foi introduzido o conceito de RSS que balanceia a carga de trabalho eficientemente entre os processadores.

O resultado no experimento de mesclagem de interrupções foi um ganho de até 76% na largura de banda em relação a configuração padrão e na de escalar o lado da recepção foi até 2,2 vezes mais também na largura de banda.

3.3.2 Análise das Informações

Nessa revisão foram encontrados diversos artigos com propostas que modificam diferentes partes da infraestrutura: *driver* de rede, placa de rede física, arquitetura da virtualização da rede e núcleo do sistema operacional. Essa variação dificultou um pouco na correlação entre os artigos.

Nos experimentos todos parecem terem feito medições em infraestruturas reais usando o *hypervisor* XEN e alguma distribuição linux como sistema operacional. Isso talvez ocorreu por eles terem o código aberto e o XEN suportar diferentes sistemas operacionais.

Todos que propuseram alguma estratégia as validaram através de medições em infraestruturas reais. Uma possível causa seria a facilidade e o baixo custo em montar uma infraestrutura com virtualização e controlar todo o processo do experimento.

3.3.3 Conclusão

A revisão ajudou a entender melhor a área de virtualização de rede. Diversas formas de melhorar o desempenho foram encontradas. Numa próxima revisão, seria interessante focar em alguma categoria para facilitar a comparação entre pesquisas.

Capítulo 4

Proposta

4.1 Tema de Pesquisa

Essa pesquisa tem como tema técnicas de otimização na virtualização de rede dentro de infraestruturas de nuvem.

4.2 Problema de Pesquisa

O problema a ser tratado nessa pesquisa é o baixo desempenho das infraestruturas em nuvem em aplicações que usam muito a rede.

4.3 Evidências do problema

Infraestruturas que normalmente utilizam técnicas de virtualização, como as infraestruturas em nuvem, têm um desempenho diferente da arquitetura de rede padrão. Alguns passos adicionais são necessários para transmitir e receber um pacote de informação de dentro de uma máquina virtual, que implicam em um custo adicional tanto na memória como no processamento [CCW⁺08] [EF10] [Liu10] [WR12] [Rix08]. Na revisão bibliográfica é possível ver melhor as propostas de cada autor.

4.4 Relevância do problema

TODO

4.5 Propostas da Literatura

Após ter feito uma revisão bibliográfica na área, no qual tivemos diversas estratégias diferentes, nessa pesquisa resolvemos direcionar o trabalho para as estratégias que tentam otimizar a mesclagem de interrupções.

[DXZL11] propuseram uma otimização por mesclagem de interrupções na recepção dentro dos *drivers* virtuais. Os autores perceberam que o pacote passa por duas camadas de *drivers* virtuais de rede antes de chegar no destino. O primeiro é o *driver* de *backend* que ficam na ponte e o outro é o *driver* de *frontend* que está dentro da máquina virtual. Considerando estas duas camadas, a combinação de mesclagem de interrupções nas duas causaria um atraso adicional no envio.

Nessa pesquisa eles focaram em otimizar os *drivers* virtuais, deixando de fora o *driver* físico.

4.6 Proposta de pesquisa

Nessa pesquisa, propomos um algoritmo para mesclagem de interrupção do *driver* da placa de rede virtual e física, tentando ajustar esses parâmetros dinamicamente de forma a garantir uma

melhor qualidade do serviço da infraestrutura de nuvem.

A proposta será uma solução se o desempenho em largura de banda e latência de aplicações que usam intensamente a rede for equivalente a uma infraestrutura sem virtualização.

4.7 Questão de pesquisa

4.8 Método de pesquisa

4.9 Cronograma

Referências Bibliográficas

- [AFG⁺09] M. Armbrust, A. Fox, R. Griffith, A.D. Joseph, R.H. Katz, A. Konwinski, G. Lee, D.A. Patterson, A. Rabkin, I. Stoica et al. Above the clouds: A berkeley view of cloud computing. *EECS Department, University of California, Berkeley, Tech. Rep. UCB/EECS-2009-28*, 2009. 1, 3, 4
- [AMN06] P. Apparao, S. Makineni e D. Newell. Characterization of network processing overheads in xen. Em *Proceedings of the 2nd international Workshop on Virtualization Technology in Distributed Computing*, página 2. IEEE Computer Society, 2006. 1, 10, 12
- [BDF⁺03] P. Barham, B. Dragovic, K. Fraser, S. Hand, T. Harris, A. Ho, R. Neugebauer, I. Pratt e A. Warfield. Xen and the art of virtualization. *ACM SIGOPS Operating Systems Review*, 37(5):164–177, 2003. 1, 4
- [CCW⁺08] V. Chaudhary, M. Cha, JP Walters, S. Guercio e S. Gallo. A comparison of virtualization technologies for hpc. Em *Advanced Information Networking and Applications, 2008. AINA 2008. 22nd International Conference on*, páginas 861–868. IEEE, 2008. 1, 3, 4, 5, 9, 10, 15
- [Cor09] Jonathan Corbet. Generic receive offload. <http://lwn.net/Articles/358910/>, 2009. Acessado em: 25/6/2012. 7, 10
- [CRKH05] Jonathan Corbet, Alessandro Rubini e Greg Kroah-Hartman. *Linux Device Drivers, 3rd Edition*. O'Reilly Media, Inc., 2005. 7
- [DXZL11] Y. Dong, D. Xu, Y. Zhang e G. Liao. Optimizing network i/o virtualization with efficient interrupt coalescing and virtual receive side scaling. Em *Cluster Computing (CLUSTER), 2011 IEEE International Conference on*, páginas 26–34. IEEE, 2011. 7, 10, 12, 15
- [Eas07] Thomas M. Eastep. Xen network environment. <http://www1.shorewall.net/XenMyWay.html>, 2007. Acessado em: 25/6/2012. ix, 6
- [EF10] J. Ekanayake e G. Fox. High performance parallel computing with clouds and cloud technologies. *Cloud Computing*, páginas 20–38, 2010. 1, 5, 9, 10, 15
- [FA12] T. Fortuna e B. Adamczyk. Improving packet reception and forwarding within virtualized xen environments. *Computer Networks*, páginas 153–160, 2012. 10, 12
- [GED⁺11] G.E. Gonçalves, P.T. Endo, T. Damasceno, A.V.A.P. Cordeiro, D. Sadok, J. Kelner, B. Melander e J.E. Mångs. Resource allocation in clouds: Concepts, tools and research challenges. *Simpósio Brasileiro de Rede de Computadores*, 2011. 1, 3
- [JSJK11] J.W. Jang, E. Seo, H. Jo e J.S. Kim. A low-overhead networking mechanism for virtualized high-performance computing systems. *The Journal of Supercomputing*, páginas 1–26, 2011. 10, 12

- [LGBK08] Guangdeng Liao, Danhua Guo, Laxmi Bhuyan e Steve R King. Software techniques to improve virtualized i/o performance on multi-core systems. Em *Proceedings of the 4th ACM/IEEE Symposium on Architectures for Networking and Communications Systems*, ANCS '08, páginas 161–170, New York, NY, USA, 2008. ACM. 10, 11
- [Liu10] J. Liu. Evaluating standard-based self-virtualizing devices: A performance study on 10 gbe nics with sr-ioV support. Em *Parallel & Distributed Processing (IPDPS), 2010 IEEE International Symposium on*, páginas 1–12. IEEE, 2010. 1, 5, 10, 11, 15
- [ON09] H. Oi e F. Nakajima. Performance analysis of large receive offload in a xen virtualized system. Em *Computer Engineering and Technology, 2009. ICCET'09. International Conference on*, volume 1, páginas 475–480. IEEE, 2009. 10, 11
- [Rix08] Scot Rixner. Network virtualization: Breaking the performance barrier. *Queue*, 6(1):37:36–37:ff, Janeiro 2008. 1, 4, 5, 10, 15
- [Sal07] K. Salah. To coalesce or not to coalesce. *AEU-International Journal of Electronics and Communications*, 61(4):215–225, 2007. 7
- [SBB⁺07] Galen M. Shipman, Ron Brightwell, Brian Barrett, Jeffrey M. Squyres e Gil Bloch. Investigations on infiniband: Efficient network buffer utilization at scale. Em *Proceedings, Euro PVM/MPI*, Paris, France, October 2007. 10
- [STJP08] Jose Renato Santos, Yoshio Turner, G. Janakiraman e Ian Pratt. Bridging the gap between software and hardware techniques for i/o virtualization. Em *USENIX 2008 Annual Technical Conference on Annual Technical Conference*, ATC'08, páginas 29–42, Berkeley, CA, USA, 2008. USENIX Association. ix, 5, 6, 7, 10, 11
- [WR12] Carl Waldspurger e Mendel Rosenblum. I/o virtualization. *Commun. ACM*, 55(1):66–73, Janeiro 2012. 1, 5, 10, 15
- [xen12] Xen best practices. <http://wiki.xen.org/wiki/XenBestPractices>, 2012. Acessado em: 25/6/2012. 11

Índice Remissivo

Computação em nuvem
fundamentos, [3](#)

Mesclagem de interrupções, [6](#)

virtualização
 aplicações da virtualização, [3](#)
 fundamentos, [3](#)
 virtualização da rede, [5](#)
 virtualização de dispositivos de E/S, [4](#)
 xen, [5](#)